Практическое задание №1

Установка необходимых пакетов:

```
In [1]: !pip install -q tqdm
         !pip install --upgrade --no-cache-dir gdown
        Looking in indexes: https://pypi.org/simple, https://us-python.pkg.dev/colab-wheels/public/simple/
        Requirement already satisfied: gdown in /usr/local/lib/python3.8/dist-packages (4.4.0)
        Collecting gdown
          Downloading gdown-4.5.4-py3-none-any.whl (14 kB)
        Requirement already satisfied: six in /usr/local/lib/python3.8/dist-packages (from gdown) (1.15.0)
        Requirement already satisfied: requests[socks] in /usr/local/lib/python3.8/dist-packages (from gdown) (2.23.0)
        Requirement already satisfied: tqdm in /usr/local/lib/python3.8/dist-packages (from gdown) (4.64.1)
        Requirement already satisfied: filelock in /usr/local/lib/python3.8/dist-packages (from gdown) (3.8.0)
        Requirement already satisfied: beautifulsoup4 in /usr/local/lib/python3.8/dist-packages (from gdown) (4.6.3)
        Requirement already satisfied: urllib3!=1.25.0,!=1.25.1,<1.26,>=1.21.1 in /usr/local/lib/python3.8/dist-packages (from requests
        [socks] \rightarrow gdown) (1.24.3)
        Requirement already satisfied: idna<3,>=2.5 in /usr/local/lib/python3.8/dist-packages (from requests[socks]->gdown) (2.10)
        Requirement already satisfied: chardet<4,>=3.0.2 in /usr/local/lib/python3.8/dist-packages (from requests[socks]->gdown) (3.0.4)
        Requirement already satisfied: certifi>=2017.4.17 in /usr/local/lib/python3.8/dist-packages (from requests[socks]->gdown) (2022.
        9.24)
        Requirement already satisfied: PySocks!=1.5.7,>=1.5.6 in /usr/local/lib/python3.8/dist-packages (from requests[socks]->gdown)
        (1.7.1)
        Installing collected packages: gdown
          Attempting uninstall: gdown
            Found existing installation: gdown 4.4.0
            Uninstalling gdown-4.4.0:
              Successfully uninstalled gdown-4.4.0
        Successfully installed gdown-4.5.4
        Монтирование Baшего Google Drive к текущему окружению:
```

Монтирование вашего Google Drive к текущему окружению.

```
In [2]: from google.colab import drive
    drive.mount('/content/drive', force_remount=True)
```

Mounted at /content/drive

Константы, которые пригодятся в коде далее, и ссылки (gdrive идентификаторы) на предоставляемые наборы данных:

```
In [3]: EVALUATE_ONLY = True
    TEST_ON_LARGE_DATASET = True
    TISSUE_CLASSES = ('ADI', 'BACK', 'DEB', 'LYM', 'MUC', 'MUS', 'NORM', 'STR', 'TUM')
    DATASETS_LINKS = {
        'train': '1XtQzVQ5XbrfxpLHJuL0XBGJ5U7CS-cLi',
        'train_small': '1qd45xXfDwdZjktLFwQb-et-mAaFeCzOR',
        'train_tiny': '1I-2ZOuXLd4QwhZQQltp817Kn3J0Xgbui',
        'test': '1RfPou3pFKpuHDJZ-D9XDFzgvwpUBFlDr',
        'test_small': '1wbRsog0n7uGlHIPGLhyN-PMeT2kdQ2lI',
        'test_tiny': '1viiB0s041CNsAK4itvX8PnYthJ-MDnQc'
}
```

Импорт необходимых зависимостей:

```
In [4]: from pathlib import Path
    import numpy as np
    from typing import List
    #from tqdm.notebook import tqdm
    #from time import sleep
    from PIL import Image
    import IPython.display
    from sklearn.metrics import balanced_accuracy_score
    import gdown
```

Класс Dataset

Предназначен для работы с наборами данных, обеспечивает чтение изображений и соответствующих меток, а также формирование пакетов (батчей).

```
In [5]: class Dataset:

    def __init__(self, name):
        self.name = name
        self.is_loaded = False
        url = f"https://drive.google.com/uc?export=download&confirm=pbef&id={DATASETS_LINKS[name]}"
        output = f'{name}.npz'
        gdown.download(url, output, quiet=False)
        print(f'Loading dataset {self.name} from npz.')
```

```
np obj = np.load(f'{name}.npz')
   self.images = np obj['data']
   self.labels = np obj['labels']
   self.n files = self.images.shape[0]
   self.is_loaded = True
    print(f'Done. Dataset {name} consists of {self.n files} images.')
def image(self, i):
   # read i-th image in dataset and return it as numpy array
   if self.is loaded:
       return self.images[i, :, :, :]
def images seq(self, n=None):
   # sequential access to images inside dataset (is needed for testing)
   for i in range(self.n files if not n else n):
       yield self.image(i)
def random image with label(self):
   # get random image with label from dataset
   i = np.random.randint(self.n files)
   return self.image(i), self.labels[i]
def random batch with labels(self, n):
   # create random batch of images with labels (is needed for training)
   indices = np.random.choice(self.n files, n)
   imgs = []
   for i in indices:
       img = self.image(i)
       imgs.append(self.image(i))
   logits = np.array([self.labels[i] for i in indices])
   return np.stack(imgs), logits
def image with label(self, i: int):
   # return i-th image with label from dataset
   return self.image(i), self.labels[i]
```

Пример использвания класса Dataset

Загрузим обучающий набор данных, получим произвольное изображение с меткой. После чего визуализируем изображение, выведем метку. В будущем, этот кусок кода можно закомментировать или убрать.

```
d_train_tiny = Dataset('train_tiny')

img, lbl = d_train_tiny.random_image_with_label()
print()
print(f'Got numpy array of shape {img.shape}, and label with code {lbl}.')
print(f'Label code corresponds to {TISSUE_CLASSES[lbl]} class.')

pil_img = Image.fromarray(img)
IPython.display.display(pil_img)

Downloading...
From: https://drive.google.com/uc?export=download&confirm=pbef&id=1I-2ZOuXLd4QwhZQQltp817Kn3J0Xgbui
To: /content/train_tiny.npz
100%| 105M/105M [00:00<00:00, 122MB/s]
Loading dataset train_tiny from npz.
Done. Dataset train_tiny consists of 900 images.

Got numpy array of shape (224, 224, 3), and label with code 0.</pre>
```

Label code corresponds to ADI class.

Класс Metrics

Реализует метрики точности, используемые для оценивания модели:

- 1. точность,
- 2. сбалансированную точность.

```
In [7]: class Metrics:

    @staticmethod
    def accuracy(gt: List[int], pred: List[int]):
        assert len(gt) == len(pred), 'gt and prediction should be of equal length'
        return sum(int(i[0] == i[1]) for i in zip(gt, pred)) / len(gt)

    @staticmethod
    def accuracy_balanced(gt: List[int], pred: List[int]):
        return balanced_accuracy_score(gt, pred)

    @staticmethod
    def print_all(gt: List[int], pred: List[int], info: str):
        print(f'metrics for {info}:')
        print('\t accuracy {:.4f}:'.format(Metrics.accuracy(gt, pred)))
        print('\t balanced accuracy {:.4f}:'.format(Metrics.accuracy_balanced(gt, pred)))
```

Класс Model

Класс, хранящий в себе всю информацию о модели.

Вам необходимо реализовать методы save, load для сохранения и заргрузки модели. Особенно актуально это будет во время тестирования на дополнительных наборах данных.

Пожалуйста, убедитесь, что сохранение и загрузка модели работает корректно. Для этого обучите модель, протестируйте, сохраните ее в файл, перезапустите среду выполнения, загрузите обученную модель из файла, вновь протестируйте ее на тестовой выборке и убедитесь в том, что получаемые метрики совпадают с полученными для тестовой выбрки ранее.

Также, Вы можете реализовать дополнительные функции, такие как:

- 1. валидацию модели на части обучающей выборки;
- 2. использование кроссвалидации;
- 3. автоматическое сохранение модели при обучении;
- 4. загрузку модели с какой-то конкретной итерации обучения (если используется итеративное обучение);
- 5. вывод различных показателей в процессе обучения (например, значение функции потерь на каждой эпохе);

- 6. построение графиков, визуализирующих процесс обучения (например, график зависимости функции потерь от номера эпохи обучения);
- 7. автоматическое тестирование на тестовом наборе/наборах данных после каждой эпохи обучения (при использовании итеративного обучения);
- 8. автоматический выбор гиперпараметров модели во время обучения;
- 9. сохранение и визуализацию результатов тестирования;
- 10. Использование аугментации и других способов синтетического расширения набора данных (дополнительным плюсом будет обоснование необходимости и обоснование выбора конкретных типов аугментации)
- 11. и т.д.

Полный список опций и дополнений приведен в презентации с описанием задания.

При реализации дополнительных функций допускается добавление параметров в существующие методы и добавление новых методов в класс модели.

```
import keras
import tensorflow as tf
from keras import layers
from keras.applications import EfficientNetV2S
from sklearn.model_selection import train_test_split
from keras import callbacks
import matplotlib.pyplot as plt
```

```
self.model 1.add(layers.Input(shape=(224, 224, 3)))
   # augmentation layer
   self.model 1.add(data augmentation)
   self.model 1.add(layers.Normalization())
   self.model 1.add(EfficientNetV2S(include top=False, input shape=(224, 224, 3)))
   self.model 1.add(layers.Flatten())
   self.model 1.add(layers.Dense(9, activation='softmax'))
   self.model 1.compile(optimizer=keras.optimizers.Adam(),
                         loss=keras.losses.SparseCategoricalCrossentropy(from logits=False),
                         metrics=['sparse categorical accuracy'])
def save(self, name: str):
    print(f'saving started')
   self.model 1.save(f'/content/drive/MyDrive/{name}.hdf5')
    print(f'saving done')
def load(self, name: str = 'best'):
    print(f'loading started')
   name to id dict = {
        'best': '1-8StHduxeVrtZAEl-5AOIPT0Y0j11Rso'
   output = f'{name}.hdf5'
    gdown.download(f'https://drive.google.com/uc?id={name to id dict[name]}', output, quiet=False)
   self.model 1 = tf.keras.models.load model(f'{name}.hdf5')
    print(f'loading done')
def loading history(self, name: str = 'model 1 cur logs'):
    print(f'loading started')
   name to id dict = {
        'model 1 cur logs': '1-49Mm 4ePquWz9ydjz6V54N807xVMc7X'
   output = f'{name}.csv'
   gdown.download(f'https://drive.google.com/uc?id={name_to_id_dict[name]}', output, quiet=False)
   self.history 1 = pd.read csv(f'{name}.csv')
    print(f'loading done')
def train(self, dataset: Dataset, val dataset = None):
   # you can add some plots for better visualization,
   # you can add model autosaving during training,
   # etc.
   print(f'training started')
```

```
if val dataset is None:
       self.train 1(dataset.images, dataset.labels)
   else:
       self.train 1(dataset.images, dataset.labels, (val dataset.images, val dataset.labels))
    print(f'training done')
def train 1(self, images train, labels train, validation data=None):
   # weights of different classes
   val, counts = np.unique(labels train, return counts=True)
   sort = np.argsort(val)
   val = val[sort]
   counts = 1 / (counts[sort] + 0.001) * labels train.shape[0] / 2
   weights = dict(zip(val, counts))
    print("weights done")
   # splitting data
   if validation data:
       images train = images train
       labels train = labels train
   else:
       # валидация
       images train, images val, labels train, labels val = train test split(images train, labels train,
                                                                                test size=0.05, random state=42)
       validation data = (images val, labels val)
   # callbacks
   initial learning rate = 0.0001
   def lr exp decay(epoch, lr):
       k = 0.1
       return initial learning rate * np.exp(-k*epoch)
   # сохранение модели
   checkpoint = keras.callbacks.ModelCheckpoint('/content/drive/MyDrive/model_1_cur.hdf5', monitor='val_loss', save_freq='e
                                                 verbose=1, save_best_only=True, save_weights_only=False, mode='auto')
   # выбор гиперпараметров
   # (количество эпох)
    earlystopping = keras.callbacks.EarlyStopping(monitor='val_loss', min_delta=0.1, patience=10, verbose=1,
                                                  mode='auto', baseline=None)
```

```
# (learning rate)
   lrscheduler = keras.callbacks.LearningRateScheduler(lr exp decay, verbose=1)
   reduce lr = keras.callbacks.ReduceLROnPlateau(monitor='val loss', factor=0.5, patience=5, verbose=1,
                                                  mode='auto', min delta=0.01, cooldown=0, min lr=0)
   # сохранение показателей
   csvlogger = keras.callbacks.CSVLogger('/content/drive/MyDrive/model 1 cur logs.csv', separator=',' , append=False)
   callbacks = [lrscheduler, checkpoint, earlystopping, reduce lr, csvlogger]
   # train
   # вывод показателей
   # (fit выводит показатели для каждой эпохи)
   self.train = self.model 1.fit(images train, labels train,
                                      epochs=self.model 1 epoch num,
                                      class weight=weights,
                                      validation data=validation data,
                                      callbacks=callbacks)
   self.history 1 = self.train.history
   self.model 1.save(f'/content/drive/MyDrive/cur trial 1.hdf5')
    print("model 1 done")
def test on dataset(self, dataset: Dataset, limit=None):
   # you can upgrade this code if you want to speed up testing using batches
   n = dataset.n files if not limit else int(dataset.n files * limit)
    predictions = self.test on dataset 1(dataset.images[:n])
   return predictions
def test on dataset 1(self, images):
    predictions 1 = tf.argmax(self.model 1.predict(images), axis=1)
   return predictions 1
def test on image(self, img: np.ndarray):
   # todo: replace this code
   img array = tf.keras.utils.img to array(img)
   img array = tf.expand dims(img array, 0)
   prediction = self.model.predict(img array)
   return prediction
def learning plots(self):
     acc = self.history 1['sparse categorical accuracy']
     val_acc = self.history_1['val_sparse_categorical_accuracy']
```

```
loss = self.history 1['loss']
                  val loss = self.history 1['val loss']
                  lr = self.history 1['lr']
                   epochs range = range(len(lr))
                  plt.figure(figsize=(15, 5))
                  plt.subplot(1, 3, 1)
                  plt.plot(epochs_range, acc, label='Training Accuracy')
                  plt.plot(epochs range, val acc, label='Validation Accuracy')
                  plt.legend(loc='lower right')
                  plt.title('Training and Validation Accuracy')
                   plt.grid()
                   plt.subplot(1, 3, 2)
                  plt.plot(epochs range, loss, label='Training Loss')
                  plt.plot(epochs range, val loss, label='Validation Loss')
                  plt.legend(loc='upper right')
                  plt.title('Training and Validation Loss')
                   plt.grid()
                  plt.subplot(1, 3, 3)
                  plt.plot(epochs range, lr, label='Learning rate')
                  plt.legend(loc='upper right')
                  plt.title('Learning rate')
                  plt.grid()
                  plt.show()
In [ ]: from sklearn.model selection import KFold
        from sklearn.metrics import balanced accuracy score
        from collections import defaultdict
In [ ]: # кросс-валидация
        def cross val(dataset: Dataset, n splits=3):
            X = dataset.images
            y = dataset.labels
            scorer = balanced_accuracy_score
            cv = KFold(n_splits=n_splits, shuffle=True, random_state=42)
            res=[]
            t = cv.split(X)
```

```
for train i, test i in t:
   X train = X[train i]
   y train = y[train i]
   X test = X[test i]
   y test = y[test i]
   model = Model()
   model.train_1(images_train=X_train, labels_train=y_train, validation_data=(X_test, y_test))
    pred = model.test on dataset 1(X test)
   res.append(scorer(y test, pred))
splits num = range(len(res))
plt.figure(figsize=(4, 3))
plt.plot(splits num, res, label='accuracy')
plt.legend(loc='lower right')
plt.title('Cross validation accuracy')
plt.ylim([0,1])
plt.grid()
plt.show()
return res
```

Классификация изображений

Классификация изображений. Используем полные датасеты train, test.

```
In []: d_train = Dataset('train')

Downloading...
From: https://drive.google.com/uc?export=download&confirm=pbef&id=18bNP8R_k8FYq0Gx0DnC2j_UEOaGqVl14
To: /content/train.npz
100%| 2.10G/2.10G [00:09<00:00, 218MB/s]
Loading dataset train from npz.
Done. Dataset train consists of 18000 images.</pre>
```

Обучение модели

Используется аугментация данных стандартными функциями библиотеки keras.layers. Далее используется архитектура

EfficientNetV2S с уже обученными на ImageNet слоями. После нее добавлен обычный полносвязный слой с 9 выходами и функцией активации softmax для окончательной классификации.

Модель обучена на 14 эпохах.

Использованы callback -функции:

- LearningRateScheduler learning rate зависит от эпохи (экспоненциально)
- ModelCheckpoint периодически сохраняет модель (только с лучшими весами)
- EarlyStopping ранняя остановка для недопуска переобучения
- ReduceLROnPlateau уменьшить learning rate , если лосс выходит на плато
- CSVLogger сохранение информации об обучении (loss, accuracy, ...) в формате .csv

```
In []: model = Model()
    if not EVALUATE_ONLY:
        model.train(d_train)
        model.save('best')
    else:
        model.load('best')
```

```
Downloading data from https://storage.googleapis.com/tensorflow/keras-applications/efficientnet v2/efficientnetv2-s notop.h5
training started
weights done
Epoch 1: LearningRateScheduler setting learning rate to 0.0001.
Epoch 1/40
535/535 [=================== ] - ETA: 0s - loss: 1.4519 - sparse categorical accuracy: 0.8936
Epoch 1: val loss improved from inf to 0.15565, saving model to /content/drive/MyDrive/model 1 cur.hdf5
56 - val sparse categorical accuracy: 0.9544 - lr: 1.0000e-04
Epoch 2: LearningRateScheduler setting learning rate to 9.048374180359596e-05.
Epoch 2/40
Epoch 2: val loss improved from 0.15565 to 0.10841, saving model to /content/drive/MyDrive/model 1 cur.hdf5
84 - val sparse categorical accuracy: 0.9633 - lr: 9.0484e-05
Epoch 3: LearningRateScheduler setting learning rate to 8.187307530779819e-05.
Epoch 3/40
Epoch 3: val loss improved from 0.10841 to 0.06697, saving model to /content/drive/MyDrive/model 1 cur.hdf5
70 - val sparse categorical accuracy: 0.9767 - lr: 8.1873e-05
Epoch 4: LearningRateScheduler setting learning rate to 7.408182206817179e-05.
Epoch 4/40
Epoch 4: val loss improved from 0.06697 to 0.04043, saving model to /content/drive/MyDrive/model 1 cur.hdf5
04 - val sparse categorical accuracy: 0.9856 - 1r: 7.4082e-05
Epoch 5: LearningRateScheduler setting learning rate to 6.703200460356394e-05.
Epoch 5/40
Epoch 5: val loss did not improve from 0.04043
34 - val sparse categorical accuracy: 0.9733 - lr: 6.7032e-05
Epoch 6: LearningRateScheduler setting learning rate to 6.065306597126335e-05.
Epoch 6/40
535/535 [========categorical_accuracy: 0.9874
Epoch 6: val loss did not improve from 0.04043
```

```
29 - val sparse categorical accuracy: 0.9767 - lr: 6.0653e-05
Epoch 7: LearningRateScheduler setting learning rate to 5.488116360940264e-05.
Epoch 7/40
535/535 [================== ] - ETA: 0s - loss: 0.1367 - sparse categorical accuracy: 0.9905
Epoch 7: val loss did not improve from 0.04043
83 - val sparse categorical accuracy: 0.9756 - lr: 5.4881e-05
Epoch 8: LearningRateScheduler setting learning rate to 4.965853037914095e-05.
Epoch 8/40
Epoch 8: val loss did not improve from 0.04043
38 - val sparse categorical accuracy: 0.9822 - 1r: 4.9659e-05
Epoch 9: LearningRateScheduler setting learning rate to 4.493289641172216e-05.
Epoch 9/40
Epoch 9: val loss improved from 0.04043 to 0.03137, saving model to /content/drive/MyDrive/model 1 cur.hdf5
Epoch 9: ReduceLROnPlateau reducing learning rate to 2.246644908154849e-05.
14 - val sparse categorical accuracy: 0.9878 - 1r: 4.4933e-05
Epoch 10: LearningRateScheduler setting learning rate to 4.0656965974059915e-05.
Epoch 10/40
Epoch 10: val loss did not improve from 0.03137
64 - val sparse categorical accuracy: 0.9856 - 1r: 4.0657e-05
Epoch 11: LearningRateScheduler setting learning rate to 3.678794411714424e-05.
Epoch 11/40
Epoch 11: val loss did not improve from 0.03137
68 - val sparse categorical accuracy: 0.9911 - lr: 3.6788e-05
Epoch 12: LearningRateScheduler setting learning rate to 3.3287108369807955e-05.
Epoch 12/40
535/535 [========categorical_accuracy: 0.9953
Epoch 12: val loss did not improve from 0.03137
```

```
00 - val sparse categorical accuracy: 0.9889 - 1r: 3.3287e-05
    Epoch 13: LearningRateScheduler setting learning rate to 3.0119421191220204e-05.
    Epoch 13/40
    Epoch 13: val loss did not improve from 0.03137
    23 - val sparse categorical accuracy: 0.9878 - lr: 3.0119e-05
    Epoch 14: LearningRateScheduler setting learning rate to 2.725317930340126e-05.
    Epoch 14/40
    Epoch 14: val loss did not improve from 0.03137
    Epoch 14: ReduceLROnPlateau reducing learning rate to 1.3626589861814864e-05.
    26 - val sparse categorical accuracy: 0.9833 - lr: 2.7253e-05
    Epoch 14: early stopping
    model 1 done
    training done
    saving started
    saving done
In [ ]
```

Тестируем на датасете test

Чтение данных

Есть возможность считывать веса и данные обучения лучшей модели.

```
In [ ]: model_1 = Model()
        model 1.load()
        loading started
        Downloading...
        From: https://drive.google.com/uc?id=1-8StHduxeVrtZAEl-5AQIPTØYQj11Rso
        To: /content/best.hdf5
        100% | 251M/251M [00:01<00:00, 152MB/s]
        loading done
In [ ]: pred 1 = model 1.test on dataset(d test, limit=1)
        Metrics.print all(d test.labels[:len(pred 1)], pred 1, 'full test')
        141/141 [========== ] - 20s 125ms/step
        metrics for full test:
                accuracy 0.9916:
                balanced accuracy 0.9916:
        import pandas as pd
In [ ]: model 1.loading history()
        loading started
        Downloading...
        From: https://drive.google.com/uc?id=1-49Mm 4ePquWz9ydjz6V54N8O7xVMc7X
        To: /content/model 1 cur logs.csv
        100% | 1.40k/1.40k [00:00<00:00, 2.91MB/s]
        loading done
In [ ]: model_1.history_1.head()
```

]:		epoch	loss	lr	sparse_categorical_accuracy	val_loss	val_sparse_categorical_accuracy
	0	0	1.451855	0.000100	0.893626	0.155648	0.954444
	1	1	0.536886	0.000090	0.961813	0.108412	0.963333
	2	2	0.366590	0.000082	0.972749	0.066970	0.976667
	3	3	0.288158	0.000074	0.980994	0.040435	0.985556
	4	4	0.217177	0.000067	0.985146	0.073438	0.973333

Визуализации

Out[

Матрица ошибок для выборки test.

```
In [10]: final_model = Model()
        final model.load('best')
        d test = Dataset('test')
        pred 1 = final model.test on dataset(d test)
        Metrics.print all(d test.labels, pred 1, 'test')
        Downloading data from https://storage.googleapis.com/tensorflow/keras-applications/efficientnet v2/efficientnetv2-s notop.h5
        loading started
        Downloading...
        From: https://drive.google.com/uc?id=1-8StHduxeVrtZAE1-5AQIPT0YQj11Rso
        To: /content/best.hdf5
        100% | 251M/251M [00:01<00:00, 127MB/s]
        loading done
        Downloading...
        From: https://drive.google.com/uc?export=download&confirm=pbef&id=1RfPou3pFKpuHDJZ-D9XDFzgvwpUBF1Dr
        To: /content/test.npz
        100% | 525M/525M [00:04<00:00, 107MB/s]
```

```
Loading dataset test from npz.
         Done. Dataset test consists of 4500 images.
         141/141 [======== ] - 720s 5s/step
         metrics for test:
                  accuracy 0.9916:
                  balanced accuracy 0.9916:
         # матрица ошибок
In [11]:
         import sklearn
         conf matr = sklearn.metrics.confusion matrix(d test.labels[:len(pred 1)], pred 1)
         disp = sklearn.metrics.ConfusionMatrixDisplay(conf matr)
         disp.plot()
         <sklearn.metrics. plot.confusion matrix.ConfusionMatrixDisplay at 0x7feae57271c0>
Out[11]:
                                                400
                                                - 300
                                                200
                                                - 100
              0 1 2 3
                       Predicted label
 In [ ]: mcm = sklearn.metrics.multilabel confusion matrix(d test.labels[:len(pred 1)], pred 1)
         tn = mcm[:, 0, 0]
         tp = mcm[:, 1, 1]
         fn = mcm[:, 1, 0]
         fp = mcm[:, 0, 1]
         print("Sensitivity for each label:")
         print(tp / (tp + fn))
         print("Specificity for each label:")
         print(tn / (tn + fp))
```

```
Sensitivity for each label:
[0.992 0.996 0.986 1. 0.998 0.996 0.988 0.972 0.996]
Specificity for each label:
[1. 0.9995 0.9995 1. 0.998 0.997 0.99925 0.9985 0.99875]
Параметры (loss, accuracy, learning rate) в процессе обучения
```

In []: final model.loading history()

loading started

Downloading...

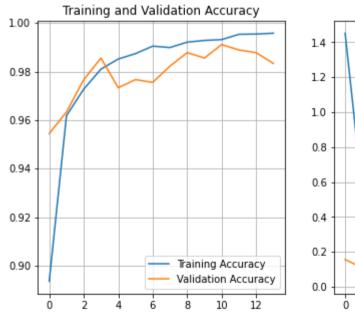
From: https://drive.google.com/uc?id=1-49Mm 4ePquWz9ydjz6V54N8O7xVMc7X

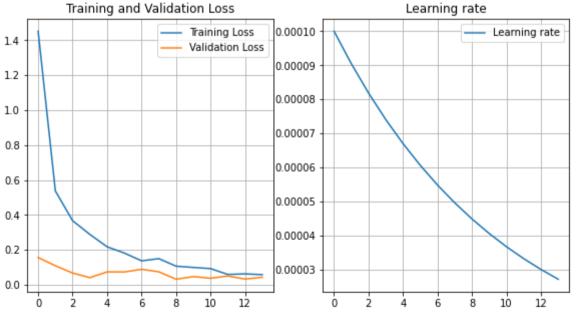
To: /content/model 1 cur logs.csv

100% | 1.40k/1.40k [00:00<00:00, 3.68MB/s]

loading done

In []: # графики обучения
final model.learning plots()





In []:

Кросс-валидация

Написана также функция кросс-валидации для модели.

Ниже приведен пример работы функции. На полном датасете проводить кросс-валидацию слишком долго, и, в общем-то, не особо имеет смысл.

Модель обучается на 5 эпохах на датасете train_tiny.

```
In []: d_train_cross = Dataset('train_tiny')

Downloading...
From: https://drive.google.com/uc?export=download&confirm=pbef&id=1zdQ4BoKXR-bRU0j0_ja5LeDjl_bPtbG0
To: /content/train_tiny.npz
100%| 105M/105M [00:00<00:00, 112MB/s]
Loading dataset train_tiny from npz.
Done. Dataset train_tiny consists of 900 images.</pre>
In []: cross_val_scores = cross_val(dataset=d_train_cross, n_splits=5)
```

weights done

```
Epoch 1: LearningRateScheduler setting learning rate to 0.001.
Epoch 1/5
Epoch 1: val loss improved from inf to 1.20344, saving model to /content/drive/MyDrive/model 1 cur.hdf5
23/23 [============== ] - 41s 907ms/step - loss: 6.3189 - sparse categorical accuracy: 0.6583 - val loss: 1.2034
- val sparse categorical accuracy: 0.8111 - lr: 0.0010
Epoch 2: LearningRateScheduler setting learning rate to 0.0009048374180359595.
Epoch 2/5
Epoch 2: val loss improved from 1.20344 to 0.46617, saving model to /content/drive/MyDrive/model 1 cur.hdf5
- val sparse categorical accuracy: 0.8889 - lr: 9.0484e-04
Epoch 3: LearningRateScheduler setting learning rate to 0.0008187307530779819.
Epoch 3/5
Epoch 3: val loss improved from 0.46617 to 0.42818, saving model to /content/drive/MyDrive/model 1 cur.hdf5
- val sparse categorical accuracy: 0.9056 - lr: 8.1873e-04
Epoch 4: LearningRateScheduler setting learning rate to 0.0007408182206817179.
Epoch 4/5
Epoch 4: val loss did not improve from 0.42818
23/23 [============= ] - 12s 519ms/step - loss: 2.2126 - sparse categorical accuracy: 0.8972 - val loss: 1.0566
- val sparse categorical accuracy: 0.8222 - lr: 7.4082e-04
Epoch 5: LearningRateScheduler setting learning rate to 0.0006703200460356394.
Epoch 5/5
Epoch 5: val loss did not improve from 0.42818
- val sparse categorical accuracy: 0.9056 - lr: 6.7032e-04
model 1 done
6/6 [======= ] - 3s 129ms/step
weights done
Epoch 1: LearningRateScheduler setting learning rate to 0.001.
Epoch 1/5
Epoch 1: val loss improved from inf to 1.53536, saving model to /content/drive/MyDrive/model 1 cur.hdf5
```

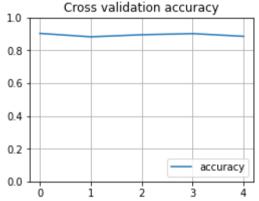
```
23/23 [============= ] - 43s 853ms/step - loss: 7.4492 - sparse categorical accuracy: 0.6431 - val loss: 1.5354
- val sparse categorical accuracy: 0.7167 - lr: 0.0010
Epoch 2: LearningRateScheduler setting learning rate to 0.0009048374180359595.
Epoch 2/5
Epoch 2: val loss improved from 1.53536 to 1.46090, saving model to /content/drive/MyDrive/model 1 cur.hdf5
23/23 [============= ] - 16s 723ms/step - loss: 6.6049 - sparse categorical accuracy: 0.7667 - val loss: 1.4609
- val sparse categorical accuracy: 0.7167 - lr: 9.0484e-04
Epoch 3: LearningRateScheduler setting learning rate to 0.0008187307530779819.
Epoch 3/5
Epoch 3: val loss improved from 1.46090 to 0.70322, saving model to /content/drive/MyDrive/model 1 cur.hdf5
- val sparse categorical accuracy: 0.8944 - lr: 8.1873e-04
Epoch 4: LearningRateScheduler setting learning rate to 0.0007408182206817179.
Epoch 4/5
Epoch 4: val loss did not improve from 0.70322
23/23 [============= ] - 12s 519ms/step - loss: 4.0621 - sparse categorical accuracy: 0.8264 - val loss: 0.8855
- val sparse categorical accuracy: 0.8833 - lr: 7.4082e-04
Epoch 5: LearningRateScheduler setting learning rate to 0.0006703200460356394.
Epoch 5/5
23/23 [=============== ] - ETA: 0s - loss: 3.3155 - sparse_categorical_accuracy: 0.8653
Epoch 5: val loss did not improve from 0.70322
23/23 [============== ] - 12s 515ms/step - loss: 3.3155 - sparse categorical accuracy: 0.8653 - val loss: 0.8769
- val sparse categorical accuracy: 0.8889 - lr: 6.7032e-04
model 1 done
6/6 [======= ] - 4s 133ms/step
weights done
Epoch 1: LearningRateScheduler setting learning rate to 0.001.
Epoch 1/5
23/23 [=================== ] - ETA: 0s - loss: 7.0102 - sparse categorical accuracy: 0.6458
Epoch 1: val loss improved from inf to 2.09458, saving model to /content/drive/MyDrive/model 1 cur.hdf5
23/23 [============== ] - 41s 918ms/step - loss: 7.0102 - sparse categorical accuracy: 0.6458 - val loss: 2.0946
- val sparse categorical accuracy: 0.7167 - lr: 0.0010
Epoch 2: LearningRateScheduler setting learning rate to 0.0009048374180359595.
Epoch 2/5
```

```
Epoch 2: val loss improved from 2.09458 to 1.53172, saving model to /content/drive/MyDrive/model 1 cur.hdf5
23/23 [============= ] - 16s 707ms/step - loss: 5.1201 - sparse categorical accuracy: 0.7972 - val loss: 1.5317
- val sparse categorical accuracy: 0.6389 - 1r: 9.0484e-04
Epoch 3: LearningRateScheduler setting learning rate to 0.0008187307530779819.
Epoch 3/5
Epoch 3: val loss improved from 1.53172 to 1.25236, saving model to /content/drive/MyDrive/model 1 cur.hdf5
23/23 [============== ] - 17s 728ms/step - loss: 3.7074 - sparse categorical accuracy: 0.8194 - val loss: 1.2524
- val sparse categorical accuracy: 0.8389 - lr: 8.1873e-04
Epoch 4: LearningRateScheduler setting learning rate to 0.0007408182206817179.
Epoch 4/5
Epoch 4: val loss improved from 1.25236 to 0.80076, saving model to /content/drive/MyDrive/model 1 cur.hdf5
23/23 [============= ] - 17s 725ms/step - loss: 3.6319 - sparse categorical accuracy: 0.8514 - val loss: 0.8008
- val sparse categorical accuracy: 0.8278 - lr: 7.4082e-04
Epoch 5: LearningRateScheduler setting learning rate to 0.0006703200460356394.
Epoch 5/5
Epoch 5: val loss did not improve from 0.80076
23/23 [============= ] - 12s 514ms/step - loss: 2.0340 - sparse categorical accuracy: 0.9208 - val loss: 0.8178
- val sparse categorical accuracy: 0.8944 - lr: 6.7032e-04
model 1 done
weights done
Epoch 1: LearningRateScheduler setting learning rate to 0.001.
Epoch 1/5
Epoch 1: val loss improved from inf to 1.83547, saving model to /content/drive/MyDrive/model 1 cur.hdf5
23/23 [============= ] - 42s 939ms/step - loss: 6.7301 - sparse categorical accuracy: 0.6403 - val loss: 1.8355
- val sparse categorical accuracy: 0.7056 - lr: 0.0010
Epoch 2: LearningRateScheduler setting learning rate to 0.0009048374180359595.
Epoch 2/5
Epoch 2: val loss did not improve from 1.83547
23/23 [============= ] - 12s 542ms/step - loss: 4.8875 - sparse categorical accuracy: 0.8264 - val loss: 1.8554
- val_sparse_categorical_accuracy: 0.7889 - 1r: 9.0484e-04
Epoch 3: LearningRateScheduler setting learning rate to 0.0008187307530779819.
```

Epoch 3/5 file:///D:/Study/MSU/Specsem/nn/Lab1/notebook final.html

```
Epoch 3: val loss improved from 1.83547 to 1.31485, saving model to /content/drive/MyDrive/model 1 cur.hdf5
23/23 [============== ] - 17s 749ms/step - loss: 3.6090 - sparse categorical accuracy: 0.8458 - val loss: 1.3149
- val sparse categorical accuracy: 0.8000 - lr: 8.1873e-04
Epoch 4: LearningRateScheduler setting learning rate to 0.0007408182206817179.
Epoch 4/5
Epoch 4: val loss improved from 1.31485 to 0.70417, saving model to /content/drive/MyDrive/model 1 cur.hdf5
- val sparse categorical accuracy: 0.8722 - lr: 7.4082e-04
Epoch 5: LearningRateScheduler setting learning rate to 0.0006703200460356394.
Epoch 5/5
23/23 [==================== ] - ETA: 0s - loss: 1.6747 - sparse categorical accuracy: 0.9097
Epoch 5: val loss improved from 0.70417 to 0.55556, saving model to /content/drive/MyDrive/model 1 cur.hdf5
23/23 [============= ] - 16s 702ms/step - loss: 1.6747 - sparse categorical accuracy: 0.9097 - val loss: 0.5556
- val sparse categorical accuracy: 0.9000 - lr: 6.7032e-04
model 1 done
weights done
Epoch 1: LearningRateScheduler setting learning rate to 0.001.
Epoch 1/5
Epoch 1: val loss improved from inf to 2.14505, saving model to /content/drive/MyDrive/model 1 cur.hdf5
23/23 [============== ] - 40s 885ms/step - loss: 6.6773 - sparse categorical accuracy: 0.6542 - val loss: 2.1450
- val sparse categorical accuracy: 0.6889 - lr: 0.0010
Epoch 2: LearningRateScheduler setting learning rate to 0.0009048374180359595.
Epoch 2/5
Epoch 2: val loss did not improve from 2.14505
- val sparse categorical accuracy: 0.7333 - 1r: 9.0484e-04
Epoch 3: LearningRateScheduler setting learning rate to 0.0008187307530779819.
Epoch 3/5
Epoch 3: val loss improved from 2.14505 to 0.59682, saving model to /content/drive/MyDrive/model 1 cur.hdf5
23/23 [================== ] - 16s 722ms/step - loss: 4.3022 - sparse_categorical_accuracy: 0.8028 - val_loss: 0.5968
- val sparse categorical accuracy: 0.8278 - lr: 8.1873e-04
```

Epoch 4: LearningRateScheduler setting learning rate to 0.0007408182206817179.



Использование аугментации данных

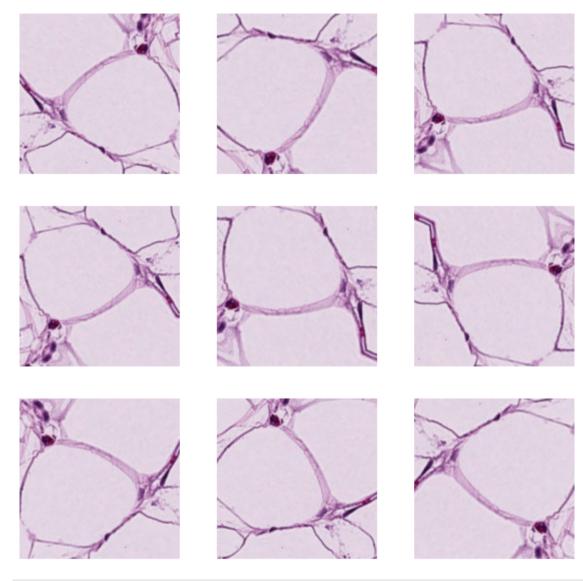
В нейронной сети используется слой аугментации данных (поворот вертикальный/горизонтальный, поворот на угол, увеличение масштаба изображения).

Выбраны параметры, не слишком сильно увеличивающие изображение (чтобы не терять в качестве). Zoom выбран исключительно отрицательным чтобы не дополнять изображение паддингом (т.к. тогда создаются зеркальные края, не всегда отражающие реальную структуру ткани).

```
In [ ]: import keras
from keras import layers
```

Epoch 4/5

```
import matplotlib.pyplot as plt
         plt.figure(figsize=(3, 3))
         images, lbl = d train.random batch with labels(1)
         print(images.shape)
         ax = plt.subplot(1, 1, 1)
         plt.imshow(images[0].astype("uint8"))
         plt.axis("off")
         (1, 224, 224, 3)
        (-0.5, 223.5, 223.5, -0.5)
Out[ ]:
        data augmentation = tf.keras.Sequential(
                    tf.keras.layers.RandomFlip(),
                    tf.keras.layers.RandomRotation(0.2),
                    tf.keras.layers.RandomZoom((-0.2, 0)),
         data_augmentation.compile(optimizer='adam',
                       loss=tf.keras.losses.SparseCategoricalCrossentropy(from_logits=False),
                       metrics=['accuracy'])
In [ ]: plt.figure(figsize=(10, 10))
         for i in range(9):
           augmented_images = data_augmentation(images, 0.1)
           ax = plt.subplot(3, 3, i + 1)
           plt.imshow(augmented_images[0].numpy().astype("uint8"))
           plt.axis("off")
```



In []:

Пример тестирования модели на полном наборе данных:

In []: # evaluating model on full test dataset (may take time)
if TEST_ON_LARGE_DATASET:

```
pred_2 = model.test_on_dataset(d_test)
Metrics.print_all(d_test.labels, pred_2, 'test')
```

Результат работы пайплайна обучения и тестирования выше тоже будет оцениваться. Поэтому не забудьте присылать на проверку ноутбук с выполнеными ячейками кода с демонстрациями метрик обучения, графиками и т.п. В этом пайплайне Вам необходимо продемонстрировать работу всех реализованных дополнений, улучшений и т.п.

Настоятельно рекомендуется после получения пайплайна с полными результатами обучения экспортировать ноутбук в pdf (файл -> печать) и прислать этот pdf вместе с самим ноутбуком.

Тестирование модели на других наборах данных

Ваша модель должна поддерживать тестирование на других наборах данных. Для удобства, Вам предоставляется набор данных test_tiny, который представляет собой малую часть (2% изображений) набора test. Ниже приведен фрагмент кода, который будет осуществлять тестирование для оценивания Вашей модели на дополнительных тестовых наборах данных.

Прежде чем отсылать задание на проверку, убедитесь в работоспособности фрагмента кода ниже.

```
In [ ]: final_model = Model()
        final model.load('best')
        d test tiny = Dataset('test tiny')
        pred = final model.test on dataset(d test tiny)
        Metrics.print all(d test tiny.labels, pred, 'test tiny')
        loading started
        Downloading...
        From: https://drive.google.com/uc?id=1-8StHduxeVrtZAE1-5AQIPT0YQj11Rso
        To: /content/best.hdf5
        100% | 251M/251M [00:00<00:00, 293MB/s]
        loading done
        Downloading...
        From: https://drive.google.com/uc?export=download&confirm=pbef&id=1JcDlKmFQ-ohdFVMQDINGY2EauuSGSVgv
        To: /content/test tiny.npz
                       | 10.6M/10.6M [00:00<00:00, 16.6MB/s]
        100%
```

Дополнительные "полезности"

Ниже приведены примеры использования различных функций и библиотек, которые могут быть полезны при выполнении данного практического задания.

Измерение времени работы кода

Измерять время работы какой-либо функции можно легко и непринужденно при помощи функции timeit из соответствующего модуля:

```
In []: import timeit

def factorial(n):
    res = 1
    for i in range(1, n + 1):
        res *= i
    return res

def f():
    return factorial(n=1000)

n_runs = 128
print(f'Function f is caluclated {n_runs} times in {timeit.timeit(f, number=n_runs)}s.')
```

Scikit-learn

Для использования "классических" алгоритмов машинного обучения рекомендуется использовать библиотеку scikit-learn (https://scikit-learn.org/stable/). Пример классификации изображений цифр из набора данных MNIST при помощи классификатора SVM:

```
In [ ]: # Standard scientific Python imports
        import matplotlib.pyplot as plt
        # Import datasets, classifiers and performance metrics
         from sklearn import datasets, svm, metrics
        from sklearn.model selection import train test split
        # The digits dataset
        digits = datasets.load digits()
        # The data that we are interested in is made of 8x8 images of digits, let's
        # have a look at the first 4 images, stored in the `images` attribute of the
        # dataset. If we were working from image files, we could load them using
         # matplotlib.pyplot.imread. Note that each image must have the same size. For these
        # images, we know which digit they represent: it is given in the 'target' of
        # the dataset.
         , axes = plt.subplots(2, 4)
        images and labels = list(zip(digits.images, digits.target))
        for ax, (image, label) in zip(axes[0, :], images and labels[:4]):
             ax.set axis off()
            ax.imshow(image, cmap=plt.cm.gray r, interpolation='nearest')
            ax.set title('Training: %i' % label)
        # To apply a classifier on this data, we need to flatten the image, to
        # turn the data in a (samples, feature) matrix:
        n samples = len(digits.images)
        data = digits.images.reshape((n samples, -1))
        # Create a classifier: a support vector classifier
        classifier = svm.SVC(gamma=0.001)
        # Split data into train and test subsets
        X_train, X_test, y_train, y_test = train_test_split(
             data, digits.target, test size=0.5, shuffle=False)
        # We learn the digits on the first half of the digits
         classifier.fit(X_train, y_train)
```

Scikit-image

Реализовывать различные операции для работы с изображениями можно как самостоятельно, работая с массивами numpy, так и используя специализированные библиотеки, например, scikit-image (https://scikit-image.org/). Ниже приведен пример использования Canny edge detector.

```
import numpy as np
import matplotlib.pyplot as plt
from scipy import ndimage as ndi
import cv2
from skimage import feature

# Generate noisy image of a square
im = d_train.images[np.random.randint(d_train.images.shape[0])][:,:,0]

# Compute the Canny filter for two values of sigma
edges1 = feature.canny(im)
edges2 = feature.canny(im, sigma=2)
ridge_filter = cv2.ximgproc.RidgeDetectionFilter_create()
edges3 = ridge_filter.getRidgeFilteredImage(im)
# display results
fig, ((ax1, ax2), (ax3, ax4)) = plt.subplots(nrows=2, ncols=2, figsize=(8, 3),
```

```
sharex=True, sharey=True)
        fig.set_size_inches(10, 10)
        ax1.imshow(im, cmap=plt.cm.gray)
        ax1.axis('off')
        ax1.set title('noisy image', fontsize=20)
        ax2.imshow(edges1, cmap=plt.cm.gray)
        ax2.axis('off')
        ax2.set title(r'Canny filter, $\sigma=1$', fontsize=20)
        ax3.imshow(edges2, cmap=plt.cm.gray)
        ax3.axis('off')
        ax3.set title(r'Canny filter, $\sigma=2$', fontsize=20)
        ax4.imshow(edges3, cmap=plt.cm.gray)
        ax4.axis('off')
        ax4.set title(r'Canny filter, $\sigma=3$', fontsize=20)
        fig.tight layout()
        plt.show()
In [ ]:
        plt.figure(figsize=(3, 3))
        images, lbl = d train.random batch with labels(1)
        print(images.shape)
        ax = plt.subplot(1, 1, 1)
        plt.imshow(images[0].astype("uint8"))
        plt.axis("off")
```

Tensorflow 2

Для создания и обучения нейросетевых моделей можно использовать фреймворк глубокого обучения Tensorflow 2. Ниже приведен пример простейшей нейроной сети, использующейся для классификации изображений из набора данных MNIST.

```
In []: # Install TensorFlow
import tensorflow as tf

mnist = tf.keras.datasets.mnist
```

Для эффективной работы с моделями глубокого обучения убедитесь в том, что в текущей среде Google Colab используется аппаратный ускоритель GPU или TPU. Для смены среды выберите "среда выполнения" -> "сменить среду выполнения".

Большое количество туториалов и примеров с кодом на Tensorflow 2 можно найти на официальном сайте https://www.tensorflow.org/tutorials?hl=ru.

Также, Вам может понадобиться написать собственный генератор данных для Tensorflow 2. Скорее всего он будет достаточно простым, и его легко можно будет реализовать, используя официальную документацию TensorFlow 2. Но, на всякий случай (если не удлось сразу разобраться или хочется вникнуть в тему более глубоко), можете посмотреть следующий отличный туториал: https://stanford.edu/~shervine/blog/keras-how-to-generate-data-on-the-fly.

Numba

В некоторых ситуациях, при ручных реализациях графовых алгоритмов, выполнение многократных вложенных циклов for в python можно существенно ускорить, используя JIT-компилятор Numba (https://numba.pydata.org/). Примеры использования Numba в Google Colab можно найти тут:

- 1. https://colab.research.google.com/github/cbernet/maldives/blob/master/numba/numba_cuda.ipynb
- 2. https://colab.research.google.com/github/evaneschneider/parallel-programming/blob/master/COMPASS_gpu_intro.ipynb

Пожалуйста, если Вы решили использовать Numba для решения этого практического задания, еще раз подумайте, нужно ли это Вам, и есть ли возможность реализовать требуемую функциональность иным способом. Используйте Numba только при реальной необходимости.

Работа с zip архивами в Google Drive

Запаковка и распаковка zip архивов может пригодиться при сохранении и загрузки Вашей модели. Ниже приведен фрагмент кода, иллюстрирующий помещение нескольких файлов в zip архив с последующим чтением файлов из него. Все действия с директориями, файлами и архивами должны осущетвляться с примонтированным Google Drive.

Создадим 2 изображения, поместим их в директорию tmp внутри PROJECT_DIR, запакуем директорию tmp в архив tmp.zip.

```
In []: PROJECT_DIR = "/dev/prak_nn_1/"
    arr1 = np.random.rand(100, 100, 3) * 255
    arr2 = np.random.rand(100, 100, 3) * 255

img1 = Image.fromarray(arr1.astype('uint8'))
    img2 = Image.fromarray(arr2.astype('uint8'))

p = "/content/drive/MyDrive/" + PROJECT_DIR

if not (Path(p) / 'tmp').exists():
        (Path(p) / 'tmp').mkdir()

img1.save(str(Path(p) / 'tmp' / 'img1.png'))
    img2.save(str(Path(p) / 'tmp' / 'img2.png'))

%cd $p
        |zip -r "tmp.zip" "tmp"
```

Распакуем архив tmp.zip в директорию tmp2 в PROJECT_DIR. Теперь внутри директории tmp2 содержится директория tmp, внутри которой находятся 2 изображения.

```
In [ ]: p = "/content/drive/MyDrive/" + PROJECT_DIR
%cd $p
!unzip -uq "tmp.zip" -d "tmp2"
```